

2026 年英特尔杯大学生电子设计竞赛嵌入式系统专题邀请赛

2026 Intel Cup Undergraduate Electronic Design Contest

- Embedded System Design Invitational Contest

作品设计报告

Final Report



Intel Cup Embedded System Design Contest

LabGuardian: 面向噪声感知输入的神经—符号解

报告题目: 耦边缘电路实验诊断系统

学生姓名: _____

指导教师: _____

参赛学校: _____

2026 年英特尔杯大学生电子设计竞赛嵌入式系统专题邀请赛

参赛作品原创性声明

本人郑重声明：所呈交的参赛作品报告，是本人和队友独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果，不侵犯任何第三方的知识产权或其他权利。本人完全意识到本声明的法律结果由本人承担。

参赛队员签名：

日 期： 年 月 日

LabGuardian：面向噪声感知输入的神经—符号解耦边缘电路实验诊断系统

摘 要

针对高校电子实验中“原理图正确但实物接错”难以发现、师生比偏高、教学诊断需可解释且安全的痛点，本文提出 LabGuardian——一个运行于英特尔边缘平台的神经—符号解耦电路实验诊断系统。系统不让大模型直接“看图判错”，而是以面包板俯视照片为输入，经自建引脚级数据集训练的关键点模型、孔位吸附与板型导通规则重构引脚级电气网表；由确定性图比对算法承担对错判断并输出可审计的结构化错误事实，再由智能体在检索契约限定的证据范围内生成自然语言解释，并以不可绕过的校验器拦截无依据陈述。教学解释模型经双教师蒸馏与 INT4 量化后部署于 Intel DK-2500，借助 NPU、iGPU 与 CPU 的异构分工实现低功耗本地推理。实验表明，NPU INT8 视觉模型达到 13.37 ms 延迟与 74.7 img/s 吞吐，端侧 INT4 学生模型约 0.88 GB、约 23 tok/s；检索契约使同一小模型由 0/6 场景无法定位故障提升至 6/6 场景正确接地，系统可在 8 GB 内存边缘设备上、以约 10 W 量级的推理工作功耗（空载约 4.4 W）完成诊断与解释。

关键词：面包板电路诊断，神经—符号，检索契约，知识蒸馏，边缘智能

LABGUARDIAN: A NEURO-SYMBOLIC EDGE SYSTEM FOR BREADBOARD CIRCUIT DIAGNOSIS UNDER NOISY PERCEPTION

ABSTRACT

To address “schematic-correct but wrongly-wired” breadboard circuits, high student-to-teacher ratios, and the need for explainable and safe feedback in electronics laboratories, this paper presents LabGuardian, a neuro-symbolic circuit-diagnosis system running on an Intel edge platform. Instead of asking a large model to directly judge an image, LabGuardian reconstructs a pin-level electrical netlist from noisy breadboard images using a self-built pin-level dataset, keypoint detection, hole snapping, and breadboard connectivity rules. A deterministic graph-comparison engine makes the correctness judgement and emits auditable structured error facts; an agent then generates explanations strictly within a retrieval contract, while an unbypassable verifier rejects ungrounded statements. The teaching-explanation model is produced by dual-teacher distillation and INT4 quantization, and is deployed on the Intel DK-2500 through heterogeneous NPU/iGPU/CPU scheduling. Experiments show that the NPU INT8 vision model reaches 13.37 ms latency and 74.7 img/s throughput, while the 0.88 GB INT4 student model runs at about 23 tok/s. With the same small model, the retrieval contract improves fault grounding from 0/6 to 6/6 demo scenarios, enabling diagnosis and explanation at an inference power on the order of 10 W (idle 4.4 W) on an 8 GB edge device.

Key words: breadboard circuit diagnosis, neuro-symbolic, retrieval contract, knowledge distillation, edge intelligence

目 录

第一章 绪论	1
1.1 教学背景与核心痛点	1
1.2 现有技术路线及其局限	1
1.3 需求分析与本文工作	1
第二章 系统方案与总体设计	3
2.1 项目定位、目的与必要性	3
2.2 核心创新与竞赛平台适配	3
2.3 总体架构	3
2.4 主业务流程	4
2.5 技术选型与设计原则	4
第三章 视觉感知与拓扑重构	5
3.1 自建引脚级面包板数据集	5
3.2 流水线编排	6
3.3 组件检测	6
3.4 全图引脚检测	6
3.5 孔位映射与导通节点解析	6
第四章 电气重构与符号诊断引擎	8
4.1 拓扑重构与结构化网表	8
4.2 参考电路的领域特定语言	8
4.3 确定性图比对算法	8
4.4 拓扑模板与三层语义匹配	9
4.5 诊断报告与错误码	9
第五章 智能解释与人机协同	11
5.1 诊断智能体与推送式上下文管理	11
5.2 知识检索契约与安全降级	11
5.3 交互端设计与结果呈现	12
5.4 人工修正闭环	12
第六章 Intel DK-2500 边缘部署与异构性能	13
6.1 本地运行与容器化部署	13
6.2 NPU、iGPU 与 CPU 的异构分工	13
6.3 异构性能实测与能效	13
6.4 端侧教学解释小模型的蒸馏与初步评测	14
第七章 实验验证与结果分析	19
7.1 功能与单元测试覆盖	19
7.2 本地检索精度评估	20
7.3 三正交消融：隔离契约、意图与蒸馏量化的各自贡献	20

7.3.1 契约消融：同一模型，契约见高下	20
7.3.2 意图路由消融	20
7.3.3 蒸馏与量化消融（教学解释质量评测）	20
7.3.4 四模型横向矩阵	22
7.4 局限	23
第八章 结论与展望	24
参考文献	25
附录	27
谢辞	28

第一章 绪论

1.1 教学背景与核心痛点

高校电子类基础实验是学生由理论走向工程实践的关键环节：学生需依据原理图，在面包板上插接电阻、电容、二极管、发光二极管、晶体管与运算放大器等元件，并借助电源、示波器与万用表观察电路现象。这一过程要求学生完成三重映射——由电路原理到元件功能、由二维原理图到面包板孔位、由实验现象到故障原因，任一映射失败都可能使实验停滞。

电子实验课普遍师生比偏高，教师难以同时覆盖所有实验台，学生常需排队等待检查；教师到场后还需逐项排查元件是否插对、引脚是否接反、孔位是否同组、电源轨是否误接、导线是否短路等基础问题。此类排查高度依赖经验、重复性强，却不能省略——极性反接与电源短路可能损坏芯片，甚至带来安全风险。

上述场景对智能诊断提出了四个超出常规视觉识别的核心难点。其一，真实图像遮挡严重：导线交叠、元件遮挡引脚与拍摄角度差异都会干扰识别，而常规目标检测只给元件级边界框、无法判定引脚插入哪一孔位，诊断因而必须深入引脚级与孔位级。其二，面包板导通关系不直观：主区按列导通、中缝隔离左右半区、电源轨可能分段，须将物理孔位映射为导通节点，才能判定相邻孔位并非同网、或两引脚短接于同一网络。其三，教学需要可解释的证据而非黑盒结论：诊断应给出错误类型及其涉及的元件、引脚、孔位与建议动作，并保留证据引用以便界面高亮。其四，系统须适应边缘环境：实验室网络未必稳定、数据不宜全部上云，故以边缘设备为主要运行平台、降低对外网依赖。

1.2 现有技术路线及其局限

围绕“判断学生电路是否正确”这一目标，现有技术路线大致可分为三类，各自存在难以回避的局限。

第一类是通用电路仿真软件。以 SPICE 为代表，它面向理想原理图、验证设计层面的正确性，却无法感知面包板上的真实接线，难以发现“原理图正确但实物接错”这一最常见的问题^[1]。

第二类是纯规则或模板比较。它借助图同构与引脚角色规则给出确定、可解释的结论，但在遇到多余元件、角色标注偏弱、输入输出网络重映射等边界情形时需不断打补丁，易判定过宽或诊断粒度不足。

第三类是端到端大模型直接看图判错。近年多模态大模型展现出强大的视觉理解能力^[2]，亦有研究进一步将其用于电路网表故障定位与端到端电路分析辅导^[3-5]；但这类方案多由模型自身承担对错判定、且普遍依赖云端算力，其输出难以审计、易生幻觉，不宜作为正误判定的唯一依据，难以满足教学对安全与可解释的严苛要求。

有鉴于此，本文采取折中且工程可落地的路线：由确定性算法构建可验证的结构化事实链承担事实判断，再由智能体在受约束的证据范围内生成解释，从而在可解释性与安全性之间取得平衡。这一“神经—符号解耦”的设计取向贯穿全文，也是本系统区别于上述三类方案的根本所在。

1.3 需求分析与本文工作

面向上述教学场景，系统需同时服务三类用户：学生希望快速知道电路哪里错、为什么错、如何改；教师与助教希望掌握多个实验台状态、定位共性错误以减少重复巡检；系统维护者则关注各模块数据契约稳定、便于后续扩展。

在功能上，系统以“图像接入 → 组件与引脚检测 → 孔位映射 → 拓扑重构 → 参考比较 → 诊断解释”为主线，识别教学常见元件、将引脚吸附至物理孔位并映射为电气节点、合并导线网络输出结构化网表、与逻辑参考电路比较生成差异报告，最终转化为学生可理解的自然语言建议；同时提供人工修正（孔位、端口、网络角色与器件标注）与结果可视化，并在服务端记录运行元数据与硬件遥测。

在非功能上，系统强调准确性、可解释性、低延迟、弱网可用、隐私保护与可扩展性：每个错误都应有证据引用与可视化目标，交互需及时，推理尽量本地运行，新增板型、元件、参考电路与故障案例时无需重写核心链路。

围绕上述需求，本文的主要工作与贡献概括如下：（1）提出面向噪声感知输入的引脚级电气网表重构方法，以关键点检测与孔位吸附替代元件级目标检测，将识别精度下沉至引脚与孔位；（2）以确定性图比对承担对错判断、智能体仅在受约束证据内生成解释，并以不可绕过的确定性校验器拦截无依据陈述，构成“神经—符号解耦”的可审计诊断链；（3）面向边缘部署，采用双教师蒸馏与 INT4 量化得到端侧教学解释模型，并在 Intel DK-2500 上以 NPU、iGPU、CPU 异构分工实现低功耗本地推理；（4）通过三组正交消融与端侧实测，分别验证检索契约、模型蒸馏与量化各自的贡献。

本文余下章节安排如下：第二章给出系统方案与总体设计；第三章阐述视觉感知与拓扑重构；第四章阐述电气重构与符号诊断引擎；第五章阐述智能解释与人机协同；第六章阐述 Intel DK-2500 边缘部署与异构性能；第七章给出实验验证与结果分析；第八章总结全文并展望后续工作。

第二章 系统方案与总体设计

2.1 项目定位、目的与必要性

LabGuardian 是面向电子实验教学的边缘智能助教系统。与在虚拟环境验证原理的通用仿真不同，它以学生实际搭建的面板照片为输入，将元件、引脚、孔位与电气连接重建为可验证、可审计的结构化事实，再与参考电路逻辑比较，输出错误位置、成因、风险等级与修改建议，把高度依赖经验的实验巡检形式化为可复现、可解释的诊断流程。

系统主线可形式化为“元件 → 引脚 → 物理孔位 → 导通节点 → 电气网络 → 结构化网表”的逐级事实链：把“某引脚在图像中接近某处”的模糊观察，逐层上升为“某引脚归属某一电气网络”的确定结论。该链路的可靠性，决定了系统能否将像素层面的连接观测转化为确定性的网络归属判断。

2.2 核心创新与竞赛平台适配

本项目的独特立意不在于简单叠加“视觉模型 + 大语言模型”，而在于把电子实验诊断拆成三条相互制约的链路：第一条是从像素到网表的感知事实链，解决真实面包板图像带噪、遮挡和孔位歧义问题；第二条是从网表到错误码的符号判定链，保证对错判断可复现、可审计；第三条是从错误码到教学语言的接地解释链，保证智能体回答不越过证据边界。三条链路共同形成“噪声感知输入—确定性诊断—受约束解释”的闭环，使系统既能体现人工智能能力，又不把安全敏感的正误判定交给不可审计模型。

英特尔竞赛平台在本项目中并非演示载体，而是系统设计的约束来源：DK-2500 的 NPU、iGPU 与 CPU 恰好对应视觉关键点推理、自回归解释生成与图算法/编排三类负载，避免单一计算单元被争抢，并使项目能以真实板端功耗与延迟数据证明“可在课堂边缘部署”，而非仅在开发机上完成算法验证（详见第六章）。

2.3 总体架构

总体架构要回答的核心问题是：如何既用上大模型的语言能力，又不让它染指安全敏感的对错判定。LabGuardian 的答案是以分层把“事实生产”与“话术生成”在结构上彻底隔开。系统采用交互端与服务端分离：交互端负责图片上传、参数与参考电路选择、结果可视化、人工修正与智能体对话；服务端负责接口接入、图像处理、模型推理、孔位映射、拓扑构建、逻辑比较、课堂状态、知识检索、智能体编排与遥测推流。整体可概括为“交互层—API 服务层—流水线事实层—领域规则层—Agent 与知识解释层—基础支撑层”六个层次，如图 2-1 所示。

六层各司其职：API 层只作协议入口；服务层负责编排、审计与任务管理；领域层承载板型规则、电路分析与验证等稳定规则；流水线层只输出结构化事实；Agent 与知识层在事实之上组织上下文、工具调用与回答；基础设施层提供异步任务、缓存与测试支撑。由此“事实生产”与“话术生成”彻底解耦——下游的自然语言解释永远以上游可证伪的结构化事实为唯一依据。




图 2-1 系统总体架构（左端发起调用，右端逐层向左提供可证伪的结构化事实）

2.4 主业务流程

一次完整诊断从交互端上传图片开始：用户选定参考电路与阈值参数后，图片提交至同步诊断接口，编排器依次执行从组件检测到语义分析的各环节，服务层把结果封装为统一诊断结果并同步到课堂状态；交互端展示事实链与诊断报告后，自动向智能体请求基于运行证据的诊断解释与下一步建议。整体流程如图 2-2 所示。

若视觉映射不准确，交互端可进入网表模式人工修正孔位、端口、网络角色或器件标注后调用重算接口；服务端不重跑视觉检测，仅从修正后的元件重新执行拓扑重构、参考验证与语义分析，以人机协同避免视觉阶段偶发错误导致系统整体不可用（详见第五章）。




图 2-2 主业务流程（上排为自动诊断主链，下排为人机协同修正回路）

2.5 技术选型与设计原则

在技术选型上，服务端以 Python 与 FastAPI 构建异步接口，视觉识别采用 YOLO 系列模型经 OpenVINO 适配英特尔异构硬件，电气比对基于图论库实现确定性图同构与子图匹配，知识检索使用本地多通道知识库，端侧解释模型由开源中文小模型蒸馏量化得到，交互端以画布叠加方式呈现识别与诊断结果。

在此之上，系统设计遵循四项原则：事实链优先——视觉模型只产生候选事实，最终结论须经板型规则、拓扑分析与验证模块约束；接口契约优先——各阶段输出与网表、诊断报告、上下文包均以统一结构化格式为协作边界，避免任何一方私自猜测；人机协同优先——允许把 AI 输出修正为可信事实后再重算；边缘可观测优先——保留模型路径、推理参数、版本号与阶段耗时，连同遥测用于分析追溯。

第三章 视觉感知与拓扑重构

本系统将“看图诊断电路”分解为可解释的事实转换步骤——组件检测、引脚检测、孔位映射、拓扑重构、参考比较各管一段，智能体仅负责解释——使每一步可独立测试、可视化与修正，从根本上抑制端到端模型难以审计、易于幻觉的风险。本章聚焦事实链前段：从图像到引脚与孔位的视觉感知与映射。

3.1 自建引脚级面包板数据集

视觉链路的可靠性首先取决于训练数据，而本场景需要的既非原理图符号数据、亦非印制电路板（PCB）器件数据，而是真实面包板照片上精确到引脚与孔位的细粒度标注。经调研，已有电路类数据集多停留在原理图识别、PCB 缺陷检测或干净网表层面^[6]，鲜有在“教学面包板 + 引脚级关键点 + 孔位映射 + 真实噪声”四个维度同时满足本任务者。为此本项目自行采集并标注了一套专用数据集，构成本系统视觉感知的基础，亦相对既有公开资源具有独创性。

数据集采集自真实实验台照片，覆盖六类教学拓扑，并刻意纳入多角度、不同光照与导线遮挡等真实变体，样本本身即贴近课堂实拍的噪声分布、无需合成增强。标注采用“组件级边界框 + 引脚级关键点”双层结构（关键点张量 3×3 ：每实例至多 3 引脚，记录横纵坐标与可见性），把识别精度从元件级下沉到引脚级——这正是常规检测数据集所不具备、却为电气诊断所必需的粒度。数据按训练 / 验证 / 测试留出划分以支持独立评测，主要规格如表 3-1 所示。

表 3-1 自建引脚级面包板数据集主要规格

数据集维度	内容
元件类别	电阻、陶瓷电容、电解电容、二极管、发光二极管、跳线、三脚晶体管（共 7 类）
标注粒度	组件边界框 + 引脚级关键点（关键点张量 3×3 ：每实例至多 3 引脚，含可见性）
覆盖拓扑	一阶 RC、共射放大、差分对、UA741 反相 / 积分 / 加法（共 6 类）
数据划分	真实实验台自采自标，按训练 / 验证 / 测试留出划分
训练配置	YOLOv8s-pose 骨干，输入 960，batch 8，训练 100 轮；INT8 由 144 张校准图训练后量化

视觉模型经由易到难的渐进路线形成：先在单元件照片上验证基础元件的可识别性；再将标注升级为 pose 形式，把任务由“识别元件是什么”推进到“识别引脚在哪里”；继而扩展电位器与双列直插芯片等复杂器件（多脚器件结合封装规则生成引脚候选）；最终过渡到真实实验板上多元件共存与遮挡的综合场景，使数据标注与模型能力同步演进。

最终的 pose 训练运行采用 Ultralytics YOLOv8s-pose^[7]，输入尺寸 960、batch size 为 8、训练 100 轮，启用默认优化器与常规颜色/平移/缩放增强，末 10 轮关闭 mosaic。训练日志显示，模型在第 100 轮的验证集上，组件检测框（B）指标为 precision=0.991、recall=0.989、mAP50=0.991、mAP50-95=0.786，引脚关键点（P）指标为 precision=0.955、recall=0.954、mAP50=0.947、mAP50-95=0.829（其中 B 指检测框指标、P 指引脚关键点指标）。上述验证集指标说明模型能较稳

定地同时完成组件定位与引脚关键点回归，为孔位映射与拓扑重构提供可用的视觉前提；测试集未参与任何训练与模型选择，留作端到端系统级评测的独立样本。

3.2 流水线编排

流水线编排器是服务端事实链的核心：以线程安全的单例复用检测器以免重复加载模型，为每次请求单独创建保存网格状态的面板校准器；接收图片、参考电路与阈值参数，依次执行组件检测到语义分析各环节，返回各阶段结果、总耗时与运行元数据。

3.3 组件检测

组件检测以面包板俯视图为输入，建立全局唯一的元件主实例与编号，作为引脚检测、孔位映射与比对的共同锚点，使下游各阶段对“同一元件”不再产生分歧。输出采用统一结构化格式（编号、类别、封装、置信度与边界框），过滤面包板本体等背景类别；对集成芯片经封装识别推断双列直插 8/14 脚，为后续引脚生成提供依据。

3.4 全图引脚检测

电气诊断要求识别精度下沉到引脚级，而常规目标检测无法回答“某引脚究竟插在哪个孔”。直觉方案是先裁剪单个元件框、再在框内回归引脚，但实践发现裁剪会把引脚切到框外并丢失周边上下文，导致系统性漏检。为此系统改采整图关键点检测：在俯视图上以 YOLO-Pose 一次性回归全部引脚关键点，再依类别与边界框的几何约束把引脚归属到对应元件，既避免裁剪误差，又保留完整引脚证据。

模型不可用时，该阶段输出格式兼容的占位结果，保证下游不因模型缺失而结构崩溃；每个引脚记录关键点坐标、可见性与综合置信度，为孔位映射提供完整证据。

3.5 孔位映射与导通节点解析

把“引脚在图像中接近某处”的模糊观测，上升为“引脚归属某一导通节点”的确定结论，是整条事实链中最易产生歧义的一步：同一关键点可能落在相邻孔位之间，单凭最近邻吸附极易误判。孔位映射因此并不简单选取最近孔，而是先用俯视图标定面包板网格（校准失败则回退合成网格并显式标记），再为每个引脚整合关键点坐标、可见性、来源与投影构造观测记录以生成候选孔位，最后依据板型规则把孔位解析为对应的导通节点。

孔位映射保留而非隐藏不确定性：每个映射后的引脚带有候选孔位、候选节点、是否歧义及原因、综合置信度、吸附距离等信息，使下游能区分高置信映射与需人工复核的低置信映射——与其在低置信处强行给出可能错误的结论，不如显式标注歧义、交由教师一键修正（见图 3-1）。

【待插入截图：交互端面包板视图——低置信引脚的歧义标记（虚线候选孔位环 + 指向各候选的虚线）】

图 3-1 低置信引脚的歧义可视化：不强行吸附，以虚线环标出候选孔位、交由教师一键确认，把“网匹配歧义”显式化为人机协同介入点

板型规则承担视觉与电气逻辑的桥梁：依孔位行列归属把物理孔位规范化为稳定导通节点，并支持据节点反查整条导通带的全部孔位、供交互端整带高亮。

在通用孔位投票之外，系统还按器件类型施加几何约束（两脚器件的引脚配对、电位器三孔共线、轴向器件不跨中缝），并由元件外形推断三极管的发射极—基极—集电极极性；这些器件级先验把“像素邻近”修正为“符合物理形态的孔位与极性”，为后续电气比对提供更可靠的引脚级事实。

第四章 电气重构与符号诊断引擎

本章是“神经—符号解耦”中的符号侧：它不依赖任何神经网络，对错判断由图论算法以确定、可复现、可审计的方式给出，从根本上杜绝了在安全敏感的“对错”问题上产生幻觉。

4.1 拓扑重构与结构化网表

视觉阶段给出“哪个引脚落在哪个孔”，电气诊断需要“哪些引脚同属一个导通网络”，拓扑重构完成这一跨越：读取孔位映射后的元件与引脚构造电路分析器，以图结构表示元件—网络关系，用并查集把导线连接的等电位孔位合并为统一网络。这里有一个易被忽视的陷阱：若沿用上游旧的节点编号，一旦人工修正了某个孔位，旧编号残留便会致错；因此系统坚持以物理孔位为唯一可信来源、据孔位重新解析导通节点。在最终的元件—网络二分图中，导线不作为元件参与拓扑、仅用于合并网络；若某非导线元件的多个引脚落入同一网络，则标记为同网络以供短路风险判断。

核心产物是结构化网表：一个保留元件、引脚、网络、节点索引与板型拓扑的结构化对象，被交互端、验证模块与智能体共同消费，亦可导出拓扑级 SPICE 网表（导线已隐式合并，元件取值暂以占位）；它同时服务于电气比较与可视化定位——选中某网络即可高亮其全部相关孔位。

4.2 参考电路的领域特定语言

参考电路的正确性直接决定诊断可信度。系统不手写网表 JSON，而以一套嵌入式 Python 领域特定语言（DSL）声明逻辑参考电路，把“作者意图”与“机器可比对结构”分离：Circuit 承载网络、元件、对称组与等价选项，Net 携带语义角色（`signal / input / output / power / ground`）与角色标签，Pin 可显式标注不连接（`no-connect`），并以等价规则（忽略孔位与元件编号、忽略无极性引脚顺序、允许多余导线）表达比对意图，最终编译为统一逻辑参考 JSON。新增参考电路只需书写数十行接近原理图的 DSL，既降低出错概率，又与比对器保持稳定数据契约。

4.3 确定性图比对算法

比对面面临一对看似矛盾的要求：学生在面包板上的摆放千差万别，不能因孔位不同就判错；但只要电气逻辑接错，又必须准确指出。逐孔位的硬规则满足其一便失之其二，难以两全。本系统的解法是把比对提升到逻辑层——在元件—网络二分图上、只对照逻辑参考电路，使“摆放不同但逻辑等价”判为正确、“逻辑网络接错”判为错误。算法分级进行：首先尝试完整图同构匹配（采用 VF2 子图同构算法^[8]，基于 networkx 图论库^[9]实现），节点按元件类型与网络角色匹配、边按引脚角色匹配。在同构之前，系统先做一次模糊组件对齐与规范名（`canonical-name`）角色传播，把参考电路的语义（如 `INV`、`VOUT`）传播到学生电路的匿名网络上，使下游消费者看到富语义；此步只更新网表语义而不重建结构图，以免干扰结构匹配的判定。

当完整同构失败时，算法逐级降级：先判断学生电路是否为参考电路的子图或包含关系（借此区分“多余连接”与“未完成电路”）；仍不成立时，才以图编辑距离（带超时）或近似相似度给出错接报告。匹配规则采用“严格/宽松”分级——电源与地、以及功能引脚（运放反相/同相输入、三极管基极-集电极-发射极、二极管与发光二极管极性、电位器中心抽头）严格匹配；电阻、电容、导线等

无极性两脚器件忽略引脚顺序；并允许合理的额外导线。相比逐孔位规则，该分级显著降低了因摆放差异导致的误报；相比纯文本规则，又对关键电气语义保持刚性约束——这正是把“对错判断”交给符号系统、而非交给易幻觉大模型的根本理由。

算法核心不是单次布尔判断，而是一条可解释的级联判定链（见表 4-1）：先尽量证明电路正确，再逐级识别失败类型并转写为稳定错误码，每个结论都能回溯到具体匹配阶段——交互端据此高亮，智能体只能引用这些结构化事实而不能臆测故障。

表 4-1 确定性图比对的级联判定链

判定阶段	算法动作	输出意义
完整同构	参考图与当前图在元件类型、网络角	判定逻辑等价，输出正确结论
角色推断	色、功能引脚约束下匹配 在不覆盖人工标注的前提下，从参考图向匿名 current 网络传播角色	降低学生未标内部信号造成的误报
包含/子图	判断当前图是否包含参考结构，或仅完成参考结构的一部分	区分“多余连接”与“未完成电路”
差异报告	生成 missing 、 extra 、 wrong 、 short 、 role mismatch 等 item	形成前端与 Agent 共享的错误事实

4.4 拓扑模板与三层语义匹配

纯图比对需要一份确定的参考电路，但同一教学拓扑常有多种合法实现（如共射的发射极可直接接地、可串电阻、可并旁路电容；加法器可有 2—5 路输入），以单一参考硬比较极易误报。为此系统引入拓扑模板，把每类规范拓扑表达为“偏规范（**partial specification**）”，以三层语义刻画结构（如表 4-2 所示）：**required** 缺失则不匹配，**optional** 可缺不扣分，**forbidden** 出现即降级或否决；另以变体与重数容纳多种合法实现，并声明参数化不变量（当前视觉管线尚未提取数值，按设计仅声明、执行留待后续）。

表 4-2 拓扑模板的三层语义结构

语义层	匹配影响	示例
required （必需）	缺失则不匹配	共射的三极管、集电极电阻、输入/输出耦合电容
optional （可选）	可缺，不扣分	共射发射极旁路电容 C_E 、偏置补偿电阻 R_p
forbidden （禁止）	出现则降级/否决	反相放大器中出现反馈电容（实为积分器）

匹配以子图同构搜索模板在学生电路图嵌入（学生电路常含模板未提及的多余导线，只要规范结构可被嵌入即可），按必需边占比计分、**forbidden** 命中扣分。模板层与图比对并行、对管线只读，把绪论所述“纯规则需不断打补丁”的边界情形系统化容纳进来。

4.5 诊断报告与错误码

参考比较与模板匹配的结论汇聚为结构化诊断报告，每条诊断项含错误码、错误族、严重程度、建议动作、证据引用及涉及的元件、引脚与孔位等字段。错误码采用稳定的确定性词表（如表 4-3 所示）——它也是后文检索契约中“验证器↔知识库”桥接的关键，故障案例正是依据错误码被精确召回。

表 4-3 诊断报告常见错误码（确定性图比对输出的稳定词表，节选）

错误码	错误族	含义与典型成因
COMPONENT_MISSING	缺件	参考电路所需元件在当前电路中缺失
WRONG_CONNECTION	接线	引脚连接到了与参考不一致的电气网络
SHORT_CIRCUIT	短路	本应分离的关键网络（电源/地、输入/输出）被合并
OPEN_CIRCUIT	开路	本应共网的引脚被分到不同网络，连接断开
OUTPUT_NODE_MISMATCH	节点	输出节点角色与参考不符（输入/电源/地同理）
CRITICAL_EXTRA_CONNECTION	多接	关键网络上存在参考未要求的额外接线
INCOMPLETE_CIRCUIT	未完成	当前电路仅匹配参考电路的一部分

诊断报告还包含面向交互端的高亮协议，把每条诊断项的证据引用转换为可直接绘制的高亮目标（元件框、引脚点、当前/目标/候选孔位）；智能体生成解释时复用同一份协议，使自然语言说明与界面定位指向同一份事实。端到端诊断示例见图 4-1。



图 4-1 端到端诊断示例：(a) 元件检测框与引脚关键点；(b) 重构的结构化网表；(c) 诊断项与证据高亮——“神经感知 → 符号判断 → 可解释定位”端到端贯通

第五章 智能解释与人机协同

得到结构化网表与诊断报告后，本章描述事实链最后一环：智能体在受控事实约束下生成解释，知识检索安全补充背景，交互端呈现证据并定位错误，人工修正与重算形成闭环。

5.1 诊断智能体与推送式上下文管理

最直接的做法是把完整网表与知识库塞进大模型上下文任其推理，但边缘小模型上下文与内存紧张，且一旦看到全部原始事实，便有“重新判断对错”的空间而引入幻觉。系统因此采用推送式上下文管理（Push-based Context Management, PCM）：按错误类型、风险等级、场景与用户问题，从课堂状态编译出仅含被推送事实、被允许工具与证据引用的最小上下文包并估算 token 控制规模。智能体只能看到被推送内容，不会越过验证模块猜测孔位或网络；这种主动压缩对内存受限的边缘部署尤为关键。

诊断智能体统一编排诊断、概念讲解、操作指导与混合问答四类教学意图：共用同一张状态图，仅按意图切换工具白名单、校验规则与回答模板（如图 5-1 所示）；工具选择进一步取决于错误族（如短路类调用网表追踪与板型查询），智能体据此动态选工具^[10]，而非把所有知识与历史塞入上下文。意图判定以确定性关键词分类为主：经实测，端侧小模型做四类意图分类的准确率与延迟均不及关键词路由，故路由交给零延迟、可解释的关键词分类，小模型只负责生成（详见第七章）。




图 5-1 一图四意图：四类意图共用同一状态图，仅按意图切换工具白名单、校验规则与回答模板

状态图以 LangGraph 为编排外壳，管理节点（错误分类、上下文构建、规划、观察、反思、回答验证、修复、定稿）的流转，并为最小化边缘部署提供行为等价的确定性顺序回退路径。其核心是职责分离：视觉、拓扑、比较与验证模块确定电路事实，大模型仅改写为自然语言而不介入判定；反思环节的确定性校验器构成模型无法绕过的强制约束——回答缺少必需错误码、证据引用或危险场景断电提示时，无论文本如何均判失败并触发修复。即便解释模型仅十亿级参数，一旦偏离既定事实即被结构化拦截，无需依赖提示工程——这正是端侧小模型在正确性敏感场景可靠应用的前提。

5.2 知识检索契约与安全降级

为避免“训练一套知识、部署另一套”的不一致，系统对智能体的检索增强生成（RAG）^[11]施加可审计约束：合法知识源仅有教学场景库、故障案例库、器件手册库与电路知识库四个通道，另加工位状态、流水线快照与参考电路等结构化事实通道（如表 5-1 所示）；早期基于通用向量库的文档检索仅保留给后台调试，禁止进入主链路或蒸馏管线，以杜绝分布漂移、云端依赖与内容污染。

表 5-1 Agent/RAG 检索契约的合法通道与约束作用

通道	内容	约束作用
教学场景库	六类 demo 场景的目标、步骤、测量点与安全提示	回答先锚定当前拓扑，避免跨实验串场
故障案例库	按场景、错误标签、错误码组织的典型故障与修复步骤	只有命中当前错误码才返回，防止凭空举例
器件手册库	UA741、LM324、NE555、BJT 等结构化 datasheet 与本地嵌入	场景白名单过滤无关芯片，端侧无外网依赖
电路知识库	放大器、积分器、比较器等原理知识	只补充教学解释，不改写诊断事实
结构化事实	工位状态、pipeline 快照、reference circuit、error codes	作为最高优先级证据，所有解释必须引用它

上述约定构成“训练即部署”的检索不变量：蒸馏数据生成与板端部署使用同一套代码、知识与场景白名单，并由起飞前自检脚本校验两端等价。它把“可用知识的边界”做成可审计的工程契约——场景白名单按拓扑过滤器件手册，使反相放大器的问题不会召回无关的定时器芯片；故障案例仅在错误码命中时返回，召回键正是第四章图比对输出的错误码词表。检索缺失时系统 fail-closed：蒸馏样本拒绝生成、部署端回退确定性模板，宁可少答也不让错误默认值污染结论。这一取向与近年电子设计自动化语言模型“以确定性结构约束生成”的方向一致^[3]；量化效果见第七章。

5.3 交互端设计与结果呈现

交互界面以 React、Vite 与 TypeScript 构建，职责是把服务端的结构化事实清晰呈现给师生。主区提供两种视图：网表视图支持孔位、端口、网络角色与引脚极性的人工修正，图像视图在原图上渲染识别框与高亮目标；点选某条诊断即据其证据引用定位到元件、引脚与孔位，使自然语言解释与界面定位指向同一份事实。

5.4 人工修正闭环

人工修正时，系统结合用户对端口、网络角色、引脚极性等的修改生成补丁，调用重算接口重新执行拓扑重构与比较——不重跑视觉检测，以极小代价纠正视觉阶段偶发偏差。视觉模型难免漏检、误检或吸附偏差，LabGuardian 保留视觉阶段的大部分事实、只对有争议的引脚或端口做局部修改再重新判断，把 AI 定位为助教而非裁判——“显式保留不确定性 + 低成本纠正回路”正是面对必然带噪的真实感知输入时仍能可靠服务教学的工程基础。

第六章 Intel DK-2500 边缘部署与异构性能

前面几章描述系统“做什么”，本章关注“在哪里运行、跑得如何”：先给出部署方式，再说明 CPU、iGPU 与 NPU 的异构分工并以板端实测的延迟、吞吐与功耗验证，最后介绍端侧小模型蒸馏与初步评测。

6.1 本地运行与容器化部署

服务端以 FastAPI 配合 Redis/Celery 组织异步接口；边缘部署采用统一模型根目录、模型以只读方式挂载，并将模型版本、推理尺寸与板型定义写入运行元数据以保证可复现。

竞赛平台并非仅作运行服务端的小主机，而是把异构计算能力纳入系统架构：OpenVINO^[12]适配端侧推理、Level-Zero 与 NPU 驱动栈负责设备调度、遥测通道实时回传利用率与功耗。平台资源与系统负载的对应关系如表表 6-1 所示。

表 6-1 Intel DK-2500 平台资源与 LabGuardian 负载映射

平台资源	系统负载	使用理由与实测依据
NPU	YOLOv8s-pose INT8 引脚关键点检测	张量计算规则、可常驻；13.37 ms、74.7 img/s，增量功耗约 4.12 W
iGPU	OpenVINO GenAI INT4 文本生成与解释	自回归生成并行度高；约 23 tok/s，CPU 对照功耗约为其 4.7 倍
CPU	图同构、子图同构、检索、服务编排、遥测	不规则控制流与图算法更适合通用核心，释放加速器给模型推理
内存	视觉模型、INT4 学生模型、知识库与服务进程共存	学生模型约 0.88 GB，解释峰值约 1.36 GB，可落入 8 GB 预算
遥测	5 Hz WebSocket 推送硬件状态与流水线阶段	把平台利用率变成可视化证据，便于课堂演示与竞赛验收

6.2 NPU、iGPU 与 CPU 的异构分工

DK-2500 搭载 Intel Core Ultra 5 225U，板端经 OpenVINO 配合 Level-Zero 与 NPU 驱动栈完成异构推理。各阶段对算力的需求差异显著：视觉检测是规则的稠密张量运算，适合专用加速器；拓扑与图论计算是不规则数据流，更适合通用核心。据此，NPU 常驻视觉关键点检测（约 75 img/s，几乎不占用其他单元），iGPU 承担自回归的解释生成与热力图，CPU 处理图同构、检索、编排与遥测等不规则逻辑。

6.3 异构性能实测与能效

为量化上述分工，项目以 turbostat 按 0.25 秒间隔采样 RAPL 能量计，并在板端以输入分辨率 960（与训练及部署一致）单进程串行采集 60 至 1153 次推理统计，测得 YOLOv8s-pose 关键点检测在 CPU、iGPU、NPU 三种单元上的延迟、吞吐与功耗。其功耗时序如图 6-1 所示：NPU 推理期间 CPU 核心与 iGPU 功率曲线全程贴近空闲基线（约 4.42 W），说明 NPU 几乎不占用其他单元资源，

为“NPU 负责视觉、iGPU 负责诊断、CPU 负责控制”的三路异构分工提供了硬件层面的可行性（本节功耗为逐单元串行采集，端到端并行加速比留待后续实测）。




图 6-1 YOLOv8s-pose INT8 在 DK-2500 上的 RAPL 功耗时序：三段分别对应 CPU/iGPU/NPU 各持续 15 秒的工作态；NPU 工作时 CPU 与 iGPU 全程贴近空闲基线，是三单元异构分工、互不争用的硬件前提

各配置详细指标如表 6-2 所示：NPU INT8 在所有维度均最优（延迟 13.37 ms、吞吐 74.7 img/s、P99 仅 15.61 ms），满足课堂实时视频流需求；INT8 经 144 张校准图训练后量化得到，模型由 22 MB 压至 11 MB，NPU 吞吐反由 60.4 升至 74.7 img/s。

表 6-2 YOLOv8s-pose 在 DK-2500 上六种设备—精度配置的延迟与吞吐实测（输入分辨率 960）

设备	精度	负载(s)	均值(ms)	P95(ms)	P99(ms)	img/s
CPU	FP16	0.14	92.44	96.74	98.92	10.8
CPU	INT8	0.24	29.02	30.13	30.65	34.5
iGPU	FP16	0.43	26.87	27.32	28.18	37.2
iGPU	INT8	2.85	18.26	19.29	20.11	54.7
NPU	FP16	1.01	16.55	16.64	17.67	60.4
NPU	INT8	1.20	13.37	13.75	15.61	74.7

能效上，NPU INT8 增量功耗仅 4.12 W、单次推理能耗 114.2 mJ、性能功耗比 18.1 ips/W，较 CPU INT8 节能约 7.1 倍。实测印证异构分工：视觉常驻负载交给 NPU，既释放 CPU 与 iGPU，又在功耗预算内满足实时性。系统另提供 5 Hz 硬件遥测与降级能力（模型缺失、校准失败时分别回退确定性模板与合成网格）。

6.4 端侧教学解释小模型的蒸馏与初步评测

第五章的诊断智能体在无可用大模型时退回确定性模板，具备算力时则由大模型承担“将结构化诊断改写为讲解”的表达环节。为使该环节脱离云端、在边缘设备上独立运行，本项目按双教师检索增强蒸馏(Retrieval-Augmented Distillation, RAD)^[13]路线训练了一款面向教学问答的端侧小模型，并完成 OpenVINO INT4 导出与初步评测。

蒸馏数据并非由教师自由生成，而是约束在系统已固化的结构化证据之上：以本地部署的 Qwen3-32B^[14]与云端的 DeepSeek-V3^[15]构成双教师，在同一份冻结证据上分别作答，把教师的语言能力与可验证事实绑定，抑制教师幻觉被放大。候选问题围绕典型电路、常见故障与学生提问意

图自动扩展，再经人工与规则联合过滤掉脱离课堂语境或与冻结证据弱相关者；教师回答亦不直接入训，仅保留具备有效引用、未降级为“证据不足”、长度达标且语义一致的样本。最终从 4990 条候选教师输出保留 3466 条高纯度样本、构建为 3450 条正式 SFT 数据（候选留存率约 69.1%）。学生模型以 Qwen2.5-1.5B-Instruct^[16]为基座，经 LoRA^[17]微调与权重合并，再以 INT4 权重量化^[18]导出为 OpenVINO 部署模型：合并后约 3.1 GB、INT4 约 0.88 GB，且随项目代码拷贝至板端即可运行、全程无需外网。

表 6-3 教学解释小模型的检索增强蒸馏与部署闭环

阶段	关键动作	防漂移约束
证据冻结	收集 scene、error codes、fault cases、datasheet hits 与 pipeline snapshot	缺场景或非法场景拒绝生成
双教师生成	Qwen3-32B 与 DeepSeek-V3 在同一证据上作答，并统一进入筛样流程	教师只能引用已给证据
学生微调	Qwen2.5-1.5B-Instruct + LoRA 监督微调并合并权重；正式 SFT 数据约 3450 条	训练样本与部署检索契约一致
INT4 导出	OpenVINO INT4 模型迁移到 DK-2500 iGPU	板端验证吞吐、内存与功耗

双教师并行候选生成提供了可量化的互补增益（如图 6-2 与表 6-4 所示）：重叠题集上 DeepSeek 分支高纯可用覆盖率 67.8%、Qwen 分支 56.8%，并行候选池在稳定性优先保留策略下升至 82.4%，较稳定教师单支路净增 14.7 个百分点；其中 14.7% 的问题仅由第二教师补充命中，说明其虽在延迟与稳定性上略弱，在长尾边界样本上仍不可替代。项目据此采用“双教师并行候选生成 + 稳定性优先保留 + 互补样本补充”的落地策略。




图 6-2 双教师候选池互补性：左为高纯可用覆盖率，右为候选池组成占比（并行候选池 82.4%，较单支路 +14.7 pp）

表 6-4 双教师候选生成的稳定性与互补性摘要（正文仅展示比例与百分点，不展开重叠题集绝对规模）

分支/候选池	生成成功率	引用合规率	高纯可用率	平均延迟	说明
DeepSeek-V3	99.8%	69.5%	69.5%	2.56 s	稳定性最高，作为稳定教师分支
Qwen3-32B	82.8%	56.8%	56.8%	7.15 s	第二教师用于补充边界样本与长尾问答
双教师候选池	—	—	82.4%	—	在重叠题集上相较稳定教师单支路提升 14.7 个百分点

项目进一步对最终 SFT 数据作分布复核（如图 6-3 与表 6-5 所示）：筛样漏斗稳定，主要质量控制发生在教师输出过滤而非 SFT 拼装阶段；意图分布未被单一“诊断问答”垄断（diagnostic 47.1%、lab_guidance 28.3%、concept_tutor 12.6%、mixed 12.0%），六类教学场景各占 13.7%—19.7%，无单一拓扑过度支配。




图 6-3 蒸馏训练集筛样漏斗（4990→3466→3450）与意图、场景、错误标签分布

表 6-5 正式 SFT 数据的筛样与分布摘要（统计来源：train_sft_alpaca.jsonl）

统计维度	结果	说明
筛样漏斗	4990 → 3466 → 3450	候选教师输出 → 高纯度教师样本 → 正式 SFT 数据
意图分布	47.1 / 28.3 / 12.6 / 12.0%	diagnostic / lab_guidance / concept_tutor / mixed
场景分布	13.7—19.7%	六类实验场景均有覆盖，最大场景 为 RC（19.7%）
风险等级	danger 5.5%，warning 81.9%， safe 12.6%	以 warning 为主，符合课堂排障问 答的主体形态
高频错误标签	缺件/悬空/错接为主	MISSING_COMPONENT 27.5%， FLOATING_CONNECTION 27.1%， WRONG_NODE_CONNECTION 19.7%
回答长度	84 / 284 / 693 字	最短 / 平均 / 最长回答长度，说明训 练文本并非极短模板

错误标签上，训练集主要覆盖缺失元件（27.5%）、悬空连接（27.1%）与节点错接（19.7%）三类高频问题，短路与回路不完整虽少但显式保留，确保模型在危险场景下不缺安全前置；同时全部样本绑定 fault_case_lookup_tool、83.7% 允许 circuit_lookup_tool，完整保留“场景证据 + 工具白名单 + 风险等级”的契约上下文——蒸馏的不是脱离环境的通用聊天模型，而是在契约约束下学习接地表达的小模型。

与以“能力迁移”为中心的主流蒸馏范式不同，本系统不追求小模型“更会推理”，而是把它训练为“受契约约束的边缘接地解释器”：其一，教师答案严格约束在冻结证据之上而非自由生成，从源头抑制教师幻觉被放大；其二，蒸馏数据生成与板端部署共享同一套检索契约与场景白名单，构成“训练即部署”不变量，消除训练—部署知识漂移；其三，学生模型部署在不可绕过的确定性校验器之后，语言能力可以偏弱、结构性事实越界即被拦截，使安全性不再依赖模型规模。这一定位与以能力为中心的蒸馏研究互补，契合神经—符号方法与可信边缘智能的方向。

项目把导出的 INT4 学生模型迁移到 DK-2500，在板端 iGPU 上完成部署态的真机性能与能耗实测：学生模型冷启动加载约 3.7 秒，首 token 延迟约 64 毫秒，解码吞吐约 23 token/s，生成约 128 token 的接地解释约需 5.5 秒；常驻内存增量约 0.35 GB、峰值约 1.36 GB，在 8 GB 板载内存预算内仍可与视觉、检索模块共存。能耗方面，空载封装功率约 4.4 W，推理时升至约 10.2 W、核显由 0 升至约 3.7 W，单次约 128 token 回答能耗约 56 焦耳；功率时序如图 6-4 所示。




图 6-4 端侧学生模型（Qwen2.5-1.5B-INT4）在 DK-2500 iGPU 上的整封装与核显功率时序：空载约 4.4 W，推理段整封装升至约 10.2 W、核显约 3.7 W，推理仅带来约 5.7 W 的整封装增量

作为对照，同一模型改在板端 CPU 运行虽吞吐相近，但整封装平均功率升至约 43 W、约为 iGPU 的 4.7 倍。这印证了设备归属决策：把自回归的解释生成放在 iGPU 以更低功率维持吞吐，把 CPU 留给拓扑与检索等控制面，而将大模型蒸馏到 1.5B 正是其装入边缘内存与功耗预算的前提。本节性能、内存与能耗均为部署态真机实测，回答质量的系统量化见第七章。

第七章 实验验证与结果分析

本章围绕三项核心设计主张组织实验证据：对错判断由确定性符号链路给出、可审计无幻觉；检索契约使端侧小模型不换模型即“答得准、答得安全”；系统可在英特尔异构边缘平台低功耗部署。功能与质量评测在开发机上以确定性方式运行，板端性能与能耗在 DK-2500 上以 turbostat 采样 RAPL 实测；第三项主张已在第六章详述，本章聚焦前两项。

表表 7-1 先汇总关键量化结果：主要证据不集中于单一模型精度，而是覆盖数据资产、确定性算法、检索契约、模型压缩、异构部署与工程测试六个维度，对应“把真实感知、符号判断、智能解释与边缘部署放在同一套可验证闭环中”的设计取向。

表 7-1 LabGuardian 关键量化结果汇总

维度	指标	结果
数据资产	自建引脚级视觉数据集	自采真实面包板照片，引脚级关键点 + 孔位映射标注
视觉部署	DK-2500 NPU INT8 延迟/吞吐	13.37 ms, 74.7 img/s, P99 15.61 ms
视觉能效	NPU INT8 增量功耗/单次能耗	约 4.12 W, 114.2 mJ, 18.1 ips/W
解释模型	INT4 学生模型体积/吞吐	约 0.88 GB, 约 23 tok/s, 峰值约 1.36 GB
检索契约	裸模型 vs 契约路径	故障接地 0/6 → 6/6, 校验通过 6/6
知识桥接	故障案例召回修复	真实错误码召回 1/6 → 6/6
工程质量	单元与契约测试	约 900+ 用例，整体通过率约 99%

7.1 功能与单元测试覆盖

确定性主张的工程基础是各模块在统一契约下行为可复现、可回归。后端以 pytest 组织约 900 余个单元与契约用例，整体通过率约 99%（个别失败为预先存在的环境依赖），分布如表 7-2 所示。

表 7-2 后端单元与契约测试覆盖分布

模块	用例数	关键断言
智能体（意图/上下文/校验器/路由）	60+	意图路由、ReAct 流程、verifier 规则
检索与知识库（RAG/KB/Agent）	55+	器件手册检索、场景检索、智能体提交
确定性图比对（拓扑/比较）	40+	图同构、子图匹配、错误码生成
视觉管线（检测/吸附/网表）	50+	校准、孔位吸附、结构化网表
其他（知识库/评估/工具）	200+	数据契约与回归
合计	约 900+	整体通过率约 99%

7.2 本地检索精度评估

检索命中正确性与跨芯片隔离是“解释严格落在正确证据上”的前提。对六类示范拓扑共设计约 32 条检索测试问题，结果如表 7-3 所示：器件手册、教学场景与语义路由由均 top-1 全命中且严格跨芯片隔离（问 UA741 不命中 LM324）；故障案例召回按错误标签匹配时存在个别边界漏识别，已在后文错误码桥接修复中改善。

表 7-3 本地四通道检索精度评估

评估项	查询数	top-1 命中率	备注
器件手册检索	12	100%	跨芯片隔离，问 UA741 不命中 LM324
教学场景检索	10	100%	按错误码与关键词
语义路由（datasheet 路由）	8	100%	自动触发 + 向量匹配
故障案例召回（按错误标签）	12	92%	1 个边界样例漏识别

7.3 三正交消融：隔离契约、意图与蒸馏量化的各自贡献

本节设计三组正交消融，每组只改变一个变量、固定其余，分别量化检索契约、意图路由与蒸馏量化的贡献——以可控对照而非主观断言支撑结论。

7.3.1 契约消融：同一模型，契约见高下

在板端用同一款 INT4 学生模型，对六个示范场景各注入一个典型故障，同一道学生问题分别走“裸模型直答”与“完整契约路径”（结果如表 7-4 所示）：裸模型六场景全部无法指认涉事器件；契约路径六场景均正确锚定场景、引用错误码与涉事器件、危险场景前置断电提示且通过校验。差异完全来自检索契约——“答得准、答得安全”不依赖更大参数量，而依赖可审计的事实约束。

表 7-4 裸模型 vs 检索契约：六示范场景诊断接地能力对照（同一 INT4 学生模型）

评估维度	裸模型直答	完整契约路径
命中涉事故障器件	0 / 6	6 / 6
引用当前错误码	0 / 6	6 / 6
引用涉事元件	0 / 6	6 / 6
危险场景安全前置	—	6 / 6
场景锚定正确	—	6 / 6
确定性校验通过	—	6 / 6

项目还核查了“验证器→知识库”的错误码桥接：诊断报告由图比对产出 diff 词表错误码，而早期故障案例库以另一套语义分析词表标注，二者几乎不相交，致真实故障下召回大量失效。以六个示范故障喂入真实 diff 码实测，修复前仅 1/6 能将目标教学案例排为首位，对齐为真实 diff 词表后升至 6/6，并在板端完成端到端验证（3/3）。这说明确定性接地链路中，词表对齐与算法同等重要。

7.3.2 意图路由消融

实测对照表明：端侧小模型直接做四类意图分类，在规范与口语化混合问题上的准确率不及关键词路由，且每次引入约 1.5—2.5 秒额外时延（与解释生成抢占同一 iGPU）；系统据此采用零延迟的确定性关键词路由承担意图判定，小模型只负责生成——以实测消融为据，而非经验默认。

7.3.3 蒸馏与量化消融（教学解释质量评测）

教学解释质量上，项目先完成部署版 INT4 的 P0 固定题集评测：30 题覆盖 6 类拓扑与 4 类意图，每题按 3 个显式命中点人工 rubric 评分。结果如图 7-1 与表 7-5 所示：平均得分率 71.1%、通过率 80.0%、满分率 40.0%，蒸馏后的小模型已能在统一题集上稳定完成多数接地解释任务。细分维度上，概念讲解与混合问答最稳（均 83.3%），步骤指导 73.3%，最难的是诊断排查类（59.0%）——模型对“解释概念、给出简明建议”已较稳，但在需要组织症状判断与排查顺序的诊断问题上仍有漏点；蒸馏与量化未破坏教学可用性，真正短板亦被固定题集客观暴露。




图 7-1 P0 固定题集人工 rubric 评测：左为部署版 INT4 整体表现（平均得分率 71.1%、通过率 80.0%），右为按意图细分——概念讲解与混合问答最好，诊断排查最具挑战

表 7-5 P0 固定题集人工评分摘要：诊断排查类难度最高，是后续优化蒸馏数据与提示约束的重点

P0 分组	题数	平均得分率	通过率	满分率
整体（INT4 部署版）	30	71.1%	80.0%	40.0%
concept_tutor	8	83.3%	87.5%	62.5%
mixed	4	83.3%	100.0%	50.0%
lab_guidance	5	73.3%	80.0%	40.0%
diagnostic	13	59.0%	69.2%	23.1%

P0.5 进一步对比本地 FP merged 与部署版 INT4：同一题集、同一约束、同一 rubric，仅换推理后端（结果如图 7-2 与表 7-6 所示）。FP 平均得分率 64.4%、INT4 为 71.1%，通过率同为 80.0%，INT4 满分率高 13.3 个百分点——量化后未见质量退化、且在满分率与整体完成度上略优。分意图看，FP 仅在 diagnostic 上占优（71.8% vs 59.0%），其余三类均为 INT4 更高；时延上 FP 约 5.8 秒、INT4 约 7.7 秒，同一量级。质量与时延差异并不单由“是否量化”决定，更受推理后端与生成收敛性影响，故 INT4 的优势应表述为更高整体得分与满分率，而非更低时延。




图 7-2 P0.5 本地 FP 与部署版 INT4 对比：左为平均得分率/通过率/满分率，右为单题平均生成时延。

INT4 得分与满分率均更高，时延与 FP 同一量级

表 7-6 P0.5 量化前后对比摘要（FP 为本地 HuggingFace merged 链路、INT4 为 OpenVINO 部署链路；不等于于板端 FP16 真机结果）

P0.5 对比项	平均得分率	通过率	满分率	平均时延
本地 FP merged	64.4%	80.0%	26.7%	5.8 s
部署版 INT4	71.1%	80.0%	40.0%	7.7 s
FP - INT4	-6.7 pp	0.0 pp	-13.3 pp	-1.93 s

7.3.4 四模型横向矩阵

项目进一步把同一题集扩展为四模型横向矩阵——未蒸馏基座、蒸馏学生 FP、蒸馏学生 INT4 与教师上限，四列共用同一题集、短答约束与 rubric；结果如图 7-3 与表 7-7 所示。

从质量侧看，未蒸馏基座、本地 FP、部署版 INT4 与教师上限的平均得分率依次为 66.7%、64.4%、71.1% 与 92.2%。需指出，基座本即具备相当通用问答能力，30 题规模下三者数个百分点的差异尚在统计噪声范围；蒸馏目标并非在裸答题得分上超越基座，其价值在于使小模型稳定产出受契约约束、可接地且含安全前置的教学解释，事实正确性由不可绕过的校验器保证、与模型规模解耦（参见契约消融 0/6 → 6/6）。本矩阵给出两点结论：部署版 INT4 相对本地 FP 未见质量退化（满分率反高 13.3 个百分点）；教师上限较 INT4 高 21.1 个百分点，界定了保持边缘可部署性前提下仍可追赶的空间。

从时延侧看，本地基座、FP 与部署版 INT4 的单题平均生成时延分别约为 4.26、5.80 与 7.73 秒，教师经云端 API 约 1.32 秒；该列反映当前实现下的端到端响应成本，而非不同参数规模的纯推理速度对比。




图 7-3 P0 四模型横向矩阵：左为平均得分率，右为当前实现链路下的单题平均生成时延。**30** 题规模下 **INT4** 与基座、**FP** 大体相当（差异在小样本噪声内），教师上限仍保留明显优势

表 7-7 P0 四模型矩阵摘要（教师列仅作质量上限参考；时延受 **API** 与本地后端差异影响，仅作参考当前链路下的响应成本比较）

四模型对比项	平均得分率	通过率	满分率	平均时延
未蒸馏基座 Qwen2.5-1.5B	66.7%	73.3%	26.7%	4.26 s
蒸馏学生 FP	64.4%	80.0%	26.7%	5.80 s
蒸馏学生 INT4	71.1%	80.0%	40.0%	7.73 s
教师上限	92.2%	96.7%	80.0%	1.32 s
INT4 - Base	+4.4 pp	+6.7 pp	+13.3 pp	+3.47 s
Teacher - INT4	+21.1 pp	+16.7 pp	+40.0 pp	-6.41 s

7.4 局限

系统在确定性链路、检索契约与边缘部署上的能力已获实测支撑；主要不足在于：评测题量仅 30 题、教师列仅作质量上限参考；蒸馏学生在无接地兜底路径上的语言质量受参数规模所限（事实层面已由校验器约束）；端到端“真实照片→正确诊断”的成功率仍需在更大真板集上统计。

第八章 结论与展望

本文提出并实现了 LabGuardian——一个面向电子实验教学、运行于英特尔边缘平台的神经—符号解耦电路诊断系统：以噪声感知输入为起点，经关键点检测与孔位吸附重构引脚级电气网表，由确定性图比承担可审计的对错判断，再由受约束的智能体在不可绕过的校验器约束下生成接地解释；教学解释模型经双教师蒸馏与 INT4 量化部署于 DK-2500，以 NPU、iGPU、CPU 异构分工实现低功耗本地推理。实测表明：NPU 以约 4 W 增量功耗达成约 75 img/s 吞吐，端侧学生模型在 iGPU 上以约 10 W、约 23 token/s 完成接地解释，整系统在 8 GB 内存预算内可用。检索契约使同一小模型从“全场景无法指认故障”跃升为“六场景全部正确接地”；四模型矩阵显示部署版 INT4（71.1%）与基座大体相当且未因量化退化，与教师上限（92.2%）约 21.1 个百分点的差距量化了可追赶空间——教学解释的事实正确性由确定性校验器保证，不依赖该得分差。

与既有工作相比，本系统的独特之处在于三点：其一，面向必然带噪的真实感知输入，而非理想的干净网表；其二，以神经—符号解耦把“对错判断”交给可审计的符号系统、把“语言表达”交给受约束的小模型；其三，以“训练即部署”的检索不变量与不可绕过的校验器，把防幻觉做成工程契约而非提示技巧。这一组合使一个十亿级小模型得以在正确性高度敏感的教学场景中、于十瓦级边缘设备上可靠运行。

后续工作将集中于四个方向：把当前 30 题四模型矩阵扩展为更大规模、多人复核的 gold 评测集，并进一步补做板端 FP16 与 INT4 的真机对比；针对 diagnostic 类题目继续增强蒸馏数据与回答约束，降低排查顺序与关键检查点的漏答率；在更大规模真板集上统计“照片→诊断”的端到端成功率；并持续扩充教学场景、故障案例与器件手册知识库，使系统覆盖更多课程实验。

参考文献

- [1] NAGEL L W, PEDERSON D O. SPICE: Simulation Program with Integrated Circuit Emphasis[R]. Berkeley: University of California, Electronics Research Laboratory, 1973.
- [2] LIU H, LI C, WU Q, et al. Visual instruction tuning[C]// Advances in Neural Information Processing Systems (NeurIPS), 2023.
- [3] ZHONG R, DU X, KAI S, et al. LLM4EDA: Emerging progress in large language models for electronic design automation[J/OL]. (2023)[2026-06-30]. <https://arxiv.org/abs/2401.12224>.
- [4] CHAUDHURI J, THAPAR D, CHAUDHURI A, et al. SPICED: Syntactical bug and Trojan pattern identification in A/MS circuits using LLM-enhanced detection[C]// IEEE Physical Assurance and Inspection of Electronics (PAINE), 2024.
- [5] CHEN L, SUN W, XIE H, et al. Enhancing large language model-based systems for end-to-end circuit analysis problem solving[J/OL]. (2025)[2026-06-30]. <https://arxiv.org/abs/2512.10159>.
- [6] SHI Y, TAO Z, GAO Y, et al. AMSnet 2.0: A large AMS database with AI segmentation for net detection[J/OL]. (2025)[2026-06-30]. <https://arxiv.org/abs/2505.09155>.
- [7] JOCHER G, CHAURASIA A, QIU J. Ultralytics YOLO[CP/OL]. (2023)[2026-06-30]. <https://github.com/ultralytics/ultralytics>.
- [8] CORDELLA L P, FOGGIA P, SANSONE C, et al. A (sub)graph isomorphism algorithm for matching large graphs[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2004, 26(10): 1367-1372.
- [9] HAGBERG A A, SCHULT D A, SWART P J. Exploring network structure, dynamics, and function using NetworkX[C]// Proceedings of the 7th Python in Science Conference (SciPy), 2008: 11-15.
- [10] YAO S, ZHAO J, YU D, et al. ReAct: Synergizing reasoning and acting in language models[C]// International Conference on Learning Representations (ICLR), 2023.
- [11] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[C]// Advances in Neural Information Processing Systems (NeurIPS), 2020.
- [12] Intel Corporation. OpenVINO Toolkit: Open Visual Inference and Neural Network Optimization[CP/OL]. [2026-06-30]. <https://github.com/openvinotoolkit/openvino>.
- [13] HINTON G, VINYALS O, DEAN J. Distilling the knowledge in a neural network[C]// NIPS Deep Learning and Representation Learning Workshop, 2015.
- [14] Qwen Team. Qwen3 Technical Report[R/OL]. (2025)[2026-06-30]. <https://arxiv.org/abs/2505.09388>.
- [15] DeepSeek-AI. DeepSeek-V3 Technical Report[R/OL]. (2024)[2026-06-30]. <https://arxiv.org/abs/2412.19437>.
- [16] Qwen Team. Qwen2.5 Technical Report[R/OL]. (2024)[2026-06-30]. <https://arxiv.org/abs/2412.15115>.

- [17] HU E J, SHEN Y, WALLIS P, et al. LoRA: Low-rank adaptation of large language models[C]// International Conference on Learning Representations (ICLR), 2022.
- [18] LIN J, TANG J, TANG H, et al. AWQ: Activation-aware weight quantization for LLM compression and acceleration[C]// Proceedings of Machine Learning and Systems (MLSys), 2024.

附录

附录 **A** 源代码与程序清单. 本作品的完整源代码、知识库与板端部署脚本随作品实物一并提交。后端服务（视觉流水线、确定性图比对、检索契约与智能体编排）、交互前端、知识库（教学场景、故障案例、器件手册、电路知识）、模型蒸馏与评测脚本，以及 DK-2500 板端性能与能耗采集脚本均在其中；关键模块的单元与契约测试见后端测试目录。

附录 **B** 扩展应用系统电路图. 六类示范教学拓扑（一阶 RC、共射放大、差分对、UA741 反相/积分/加法）的逻辑参考电路定义与对应故障案例随知识库提交，可作为系统扩展到更多课程实验的样例。

附录 **C** 应用资料与参考文献目录. 见上节参考文献；器件手册原始资料（UA741、LM324、NE555、S8050 等）随器件手册知识库提交。

谢辞

在本报告完成之际，谨向在项目研究与报告撰写过程中给予悉心指导的指导教师，以及给予帮助与支持的队友、同学与提供竞赛平台与技术支持的英特尔公司表示衷心的感谢。